ДИЗАЙН-РЕВЬЮ · ЧАТ ПОДДЕРЖКИ НА LLM

Дешевле — и клиенты не заметят

Как снизить стоимость чата на Claude Sonnet
и доказать, что качество не упало

3 способа сделать дешевле

3 слоя проверки качества

ЗАЧЕМ

Задача: меньше денег, то же доверие

ДЕНЬГИ

84.6K

токенов уходит на один разговор из 6 ходов, а новых из них — только 9.6K. Каждый ход заново отправляет инструкции и всю историю.

ДОВЕРИЕ

≈ $8

стоит один контакт с оператором, против $0.10 у самообслуживания. Бот, который чаще зовёт человека, съедает всю экономию. Klarna в 2025 вернула людей: дешёвый ИИ давал хуже качество.

Цель: $ за решённый разговор вниз, а поведение и оценки клиентов — не хуже.

Источники: Gartner, 2019; Entrepreneur о Klarna, 05.2025. Профиль токенов — модель, уточняем замером.

ПЛАН

Две группы методов, идём по порядку

Сделать дешевле

1. **Prompt caching** — не платим дважды за повторы — незаметно
2. **Меньше thinking** — ниже effort на простых вопросах — проверяем
3. **Model routing** — дешёвая модель — для проверенных тем — проверяем

Доказать, что не хуже

A. **Evals и бэктесты** — до клиентов: task success, tool calls, LLM-judge

B. **Поведение** — в проде: resolution, re-contact, rephrase

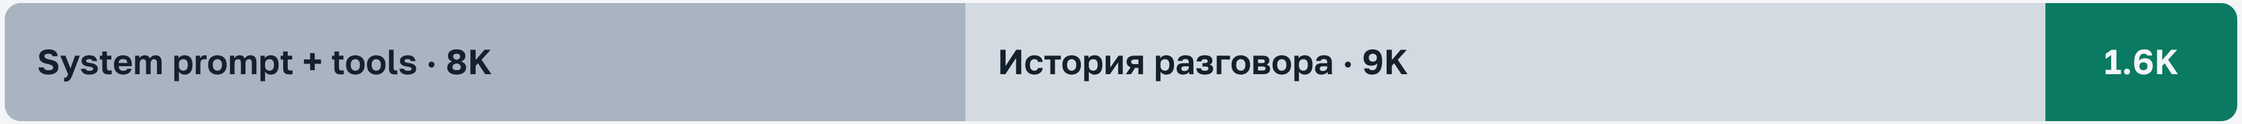
C. **Люди** — blind side-by-side, satisfaction, жалобы

Каждый метод слева проходит нужные ему проверки справа. Сводная таблица — в конце.

ДЕШЕВЛЕ · 1 ИЗ 3

Prompt caching: не платим дважды

Так выглядит запрос на 6-м ходу разговора. Почти всё в нём уже отправлялось раньше.



уже отправляли → cache read, 10% цены новое → cache write, 125%

Постоянное — в начало

System prompt, tools, правила компании — одинаковые для всех чатов.

Меняющееся — в конец

Имя клиента, время, данные аккаунта — в последнее сообщение, а не в инструкции.

История — append-only

Старые ходы не правим и не обрезаем: любая правка сбрасывает кэш.

Anthropic: до -90% стоимости и -85% задержки на длинных промптах («Prompt caching with Claude»)

ДЕШЕВЛЕ · 1 ИЗ 3 · ПРИМЕР

Prompt caching на диалоге: разбитый экран

Ход 1	«Разбил экран телефона, что делать?»
Ход 2	«Полис на iPhone 15, номер в письме»
Ход 3	«Фото загрузил, что дальше?»
Ход 4	«Сколько ждать ремонта?»
Ход 5	«А франшиза какая?»
Ход 6	«Курьер сам заберёт телефон?»



16.9¢ → 4.1¢
вход за весь разговор, −76%

21.7¢ → 8.9¢
с ответами, −59%, ответы те же

10 с → 2.5 с
TTFT в длинном диалоге

Пример диалога; токены — модель (8К инструкций, 1.5К документов на ход). Время — Anthropic, «Prompt caching».

ДЕШЕВЛЕ · 2 ИЗ 3

Меньше thinking на простых вопросах

Клиент: «Сколько ждать ремонта?»

Effort high — как сейчас



0.8¢ за ход

Effort low



0.35¢ за ход · весь разговор 8.9¢ → 6.2¢ (−30%)

92%

случаев верен уже первый вариант, остальное — перерасход (Chen et al., 2024)

98.9%

точности на бенчмарке поддержки при low effort, 2.6¢ за тикет (Anthropic)

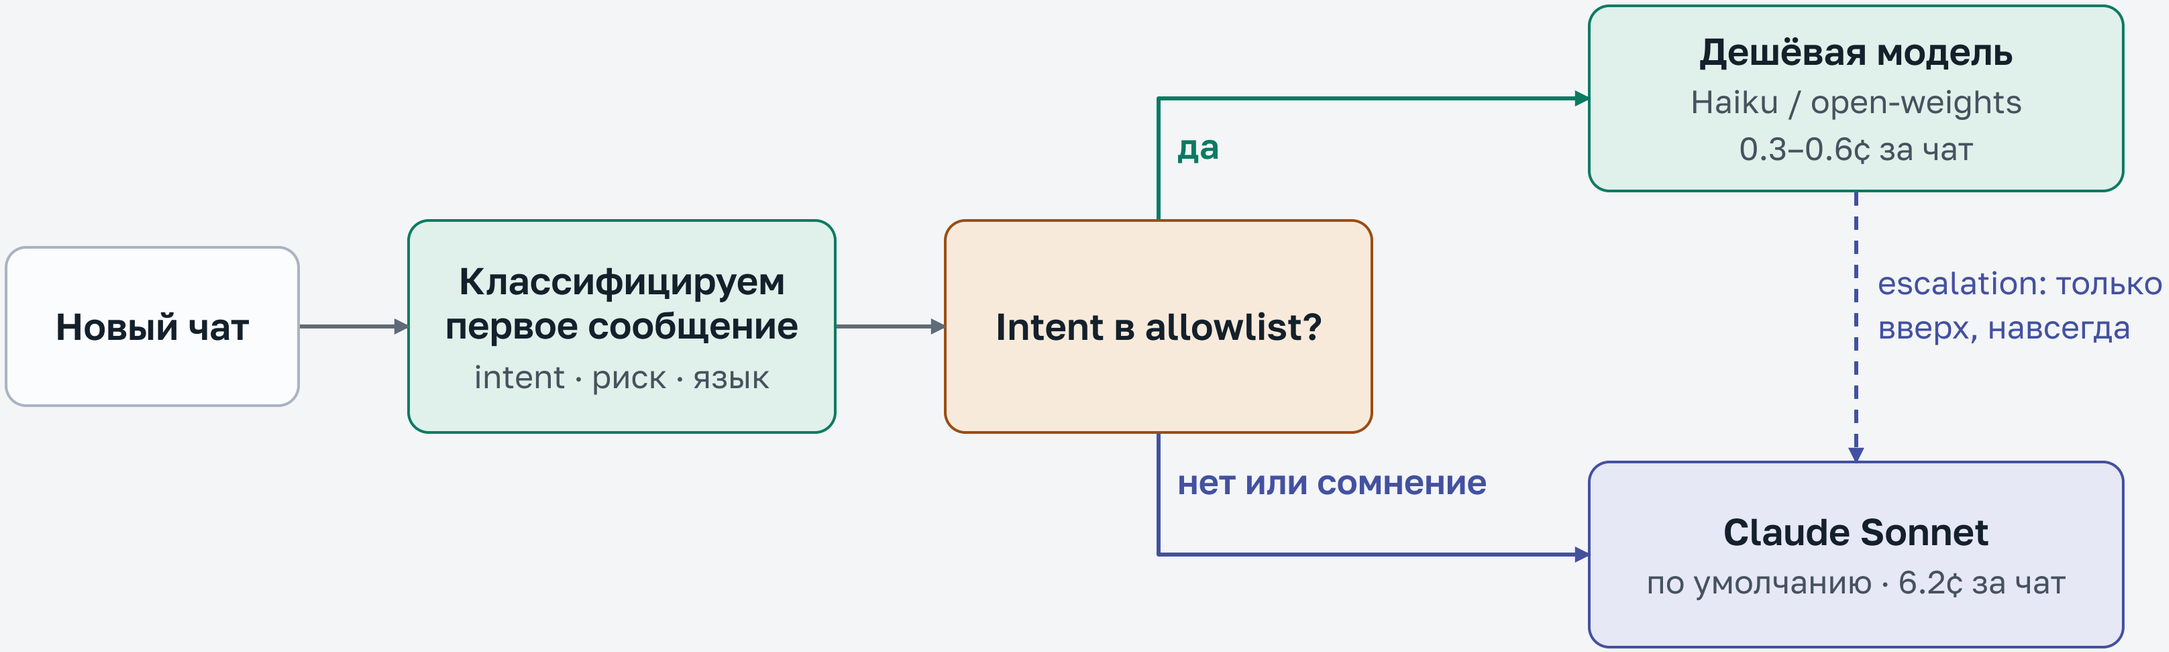
Урок Claude Code, 2026

Effort снизили — тесты почти не заметили, люди заметили. Поэтому low только для простых тем и через A/B.

Токены — модель. Thinking оплачивается как output-токены, в 5 раз дороже input.

ДЕШЕВЛЕ · 3 ИЗ 3

Model routing: дешёвая модель для простых тем



Sticky: одна модель на чат

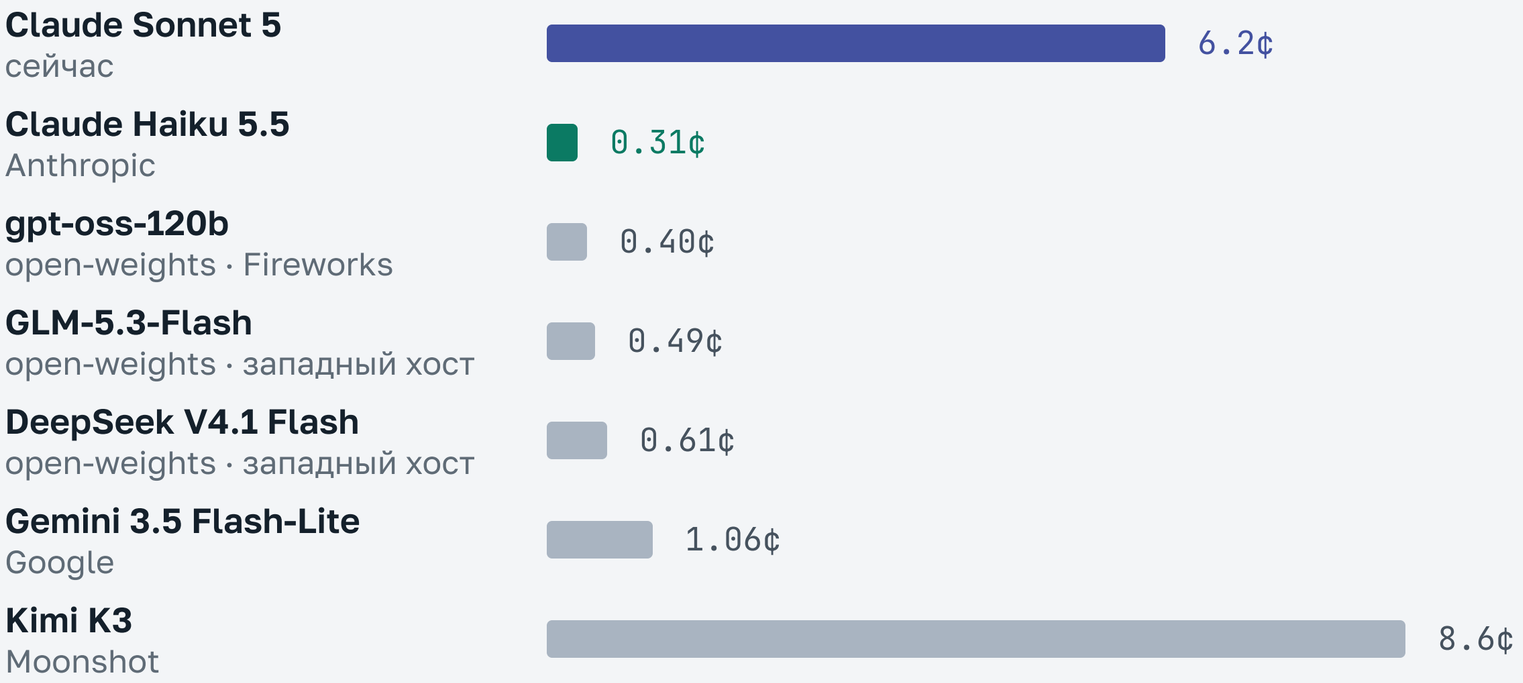
Escalation только вверх

Unsure → Sonnet

RouteLLM (LMSYS, 2024): -85% стоимости при 95% качества сильной модели на MT Bench

ДЕШЕВЛЕ · 3 ИЗ 3 · КАКУЮ МОДЕЛЬ

Цена одного разговора у разных моделей



Все дешёвые — 0.3–1¢

Разница меньше цены одной лишней передачи оператору. Выбираем по качеству.

Свой API DeepSeek

хранит данные в Китае. Те же веса — у западного хостинга.

Китайская ≠ дешёвая

Kimi K3 дороже Sonnet.

Официальные прайсы на 19.10.2026; один и тот же диалог, кэш учтён

ДЕШЕВЛЕ · ИТОГ

Итог по деньгам: −83% на разговор



Но экономия считается в $ за решённый разговор: лишняя передача оператору (~$8) съедает её целиком. Дальше — как доказать, что качество не упало.

Модель: 6 ходов, 8К инструкций, цены Anthropic. Первый шаг — замерить реальный профиль токенов.

НЕ ХУЖЕ · ЗАЧЕМ ТРИ СЛОЯ

Метрики растут, а людям хуже: четыре случая

OpenAI · GPT-4o · апрель 2025

Thumbs up выросли — модель стала sycophantic

Поймали: тестеры «что-то не так», жалобы в соцсетях

Урок: sycophancy-evals блокируют релиз

Anthropic · Claude Code · март 2026

Снизили effort — evals почти не заметили

Поймали: /feedback в продукте и публичные примеры

Урок: изменения «ума» — постепенно

OpenAI · GPT-5 · август 2025

Рекорды бенчмарков, но не хватило «тепла»

Поймали: Reddit AMA и отмены подписок

Урок: тон — тоже качество

Anthropic · сентябрь 2025

Баги портили ответы неделями

Поймали: жалобы пользователей, evals не видели

Урок: evals — постоянно на проде

И наоборот: в исследовании METR разработчики с ИИ работали на 19% медленнее, но были уверены, что на 20% быстрее. Нужны и цифры, и люди.

OpenAI 02.05.2025 · Anthropic 17.09.2025 и 23.04.2026 · TechRepublic 11.08.2025 · METR 10.07.2025

НЕ ХУЖЕ · ОБЗОР

Три слоя: evals, поведение, люди

A Evals

до клиентов: бэктест

- task success, pass^k
- tool-call accuracy
- turns и tool calls
- LLM-judge vs baseline

Слабое место: не видит, как ответ ощущается.

B Поведение

в проде, A/B по клиентам

- resolution rate
- re-contact за 7 дней
- rephrase, escalation
- abandonment

Слабое место: видно «что», но не «почему».

C Люди

каждую неделю, выборка чатов

- blind side-by-side
- LLM-оценка satisfaction
- жалобы и отзывы
- CSAT и thumbs, с поправкой

Слабое место: мало данных, смещено, дорого.

Каждый слой ловит то, что пропускают другие.

Evals и бэктесты: проверка до клиентов

Метрика	Что ловит	Scorer в Sophie Lab
Task success, pass^k	нестабильное решение	verdict.agreement
Tool-call accuracy	не та выплата	payout.accuracy, expectations.toolCalls
Лишние шаги и письма	модель «буксует»	emails.sentCount, counterparty.redundantAsk
Sycophancy	уступил против правил	verdict.agreement, judge.rubric
LLM-judge vs baseline	текст и тон писем	judge.communication

LLM-judge совпадает с людьми в 85% случаев, но после перестановки ответов держит вердикт лишь в 65% — поэтому сравниваем в обе стороны и сверяем с handler-ами.

Бэктест в Sophie Lab

Исторический claim прогоняем «на момент времени»: Sophie предлагает действия, scorers сравнивают их с тем, что сделал handler.

Sophie UI

Sophie предлагает — handler жмёт approve, edit или reject. Approve-without-edit rate — живой сигнал качества, а каждая правка — новый кейс для бэктеста.

Sophie Lab scorers · Anthropic, «Demystifying evals for AI agents», 01.2026 · Zheng et al., 2023

НЕ ХУЖЕ · В · ПОВЕДЕНИЕ

Что клиенты делают, а не что говорят

A/B по клиентам. Guardrails и non-inferiority margin — заранее:

Resolution rate (без человека)	≥ -1 п.п.
Re-contact за 7 дней	≤ +0.5 п.п.
Rephrase / correction rate	≤ +1 п.п.
Escalation на человека	≤ +0.5 п.п.
Abandonment	≤ +1 п.п.

0.6%

ответов получили thumbs up/down во внутреннем чате Google. Поведение есть у каждого чата (Google, 2025)

> 50%

реплик в конце длинных диалогов — поправки и переспросы. Это и есть сигнал недовольства (EMNLP 2025)

Margins — пример, подписываем до старта. Nam et al. (Google), 2025 · Liu, Zhang, Choi, EMNLP 2025

НЕ ХУЖЕ · С · ЛЮДИ

Как измерить, что людям нравится

Blind side-by-side

QA раз в неделю видит два ответа на один вопрос без подписи модели и выбирает лучший.

Как Chatbot Arena: толпа и эксперты согласны в 73–83%

LLM-оценка satisfaction

ИИ оценивает каждый чат по рубрике (SPUR, Microsoft): 100% чатов, а не доли процента.

С людьми: по темам r = 0.8, по одному чату — 0.3

Жалобы и negative sentiment

Группируем жалобы и раздражение: «стал холоднее», «поддакивает», «не понял».

Negative sentiment в тексте в 13 раз чаще thumbs down

CSAT и thumbs — с поправкой

Отвечают немногие, чаще крайние. Именно на thumbs up GPT-4o стал sycophantic.

Смотрим, но не оптимизируем под них

Правило Anthropic: каждую неделю читать выборку живых чатов глазами.

Chiang et al., 2024 · Lin et al. (SPUR), 2024 · Tomlinson et al., 2025 · Nam et al., 2025 · OpenAI, 05.2025

СВОДКА

Какая проверка нужна каждому методу

Метод	A · Evals	B · Поведение	C · Люди	Holdout 90 дней
Prompt caching	не нужны: ответы те же	только $, скорость, доля кэша	не нужно	не нужен
Меньше thinking	LLM-judge на hard cases	A/B, 2+ недели	blind side-by-side на hard cases	не нужен
Model routing	полный бэктест в Sophie Lab	A/B по каждому intent	blind side-by-side, тон, жалобы	5% клиентов на старой схеме

Чем сильнее меняется поведение модели, тем больше слоёв проверки.

КАК ВЫКАТЫВАЕМ

Каждое изменение проходит четыре ступени

1

Бэктест

старые чаты, LLM-judge и люди; клиенты не видят

не хуже в ≥95% ответов

→

2

Canary

1–5% клиентов на 72 часа

ничего не сломалось

→

3

A/B-тест

50/50 по клиентам, 2+ недели

все пороги держатся с 95% уверенностью

→

4

Holdout

5% клиентов на старой схеме 90 дней

нет медленного оттока

Любое нарушение guardrail — флаг за секунды возвращает старую схему.

ИТОГ

Сначала бесплатное: prompt caching.

Остальное — только через проверку.

Доказательство — поведение и люди, а не одна метрика.

−59%
prompt caching, без риска

−71%
+ меньше thinking

−83%
+ routing на половине чатов